

# Software & Programming of HPC Systems

## ΕΡΓΑΣΙΑ 2: SIMD and CUDA

Φλουρής Παντελής, up1093507

Κολτσάκης Χρυσάφης, up1084671

## 1. SIMD and WENO5

**A)**

Η ενεργοποίηση των GCC flags **-O1 -march=native -ftree-vectorize** στον αρχικό κώδικα δεν παρείχε καμία βελτιστοποίηση. Αυτό εύκολα λύθηκε με μετατροπή της `weno_minus_core` σε `static inline`, επιτρέποντας στον GCC να την κάνει `vectorize`. Δίνουμε στα `pointers` που περνώνται στην `weno_minus_reference` το attribute `__restrict__`, βοηθώντας τον `compiler` να καταλάβει ότι είναι `aligned`.

Μετά απο αυτή την αλλαγή, ο gcc δημιουργεί δυο εκδόσεις: Μια χρησιμοποιώντας SSE και μία χρησιμοποιώντας AVX, πετυχαίνοντας έτσι μεγαλύτερη συμβατότητα με παλαιότερα συστήματα.

```
-> % make
rm -f bench perf*
gcc -O1 -ftree-vectorize -march=native -ffast-math -fopt-info-optimized -o bench bench.c -lm
weno.h:36:20: optimized: loop vectorized using 32 byte vectors
weno.h:36:20: optimized: loop vectorized using 16 byte vectors
weno.h:37:18: optimized: loop turned into non-loop; it never loops
```

Η χρήση OpenMP vectorization ήταν πιο απλή αλλά λιγότερο αποδοτική. Στον αρχικό πηγαίο κώδικα, καναμε μόνο αυτές τις αλλαγές:

- Προσθήκη <omp.h>
- #pragma omp declare simd στις συναρτήσεις  
weno\_minus\_reference και weno\_minus\_core

- `#pragma omp simd aligned(a, b, c, d, e, out:32)` στο for loop (32 διότι οι μεταβλητές είναι aligned στα 32 bytes).

Αξίζει να σημειωθεί ότι η χρήση των OpenMP directives στον κώδικα του πρώτου υποερωτήματος (με τα compiler vectorizations) δεν παρείχε καμία βελτίωση).

```
gcc -O1 -fopenmp-simd -fopenmp -ffast-math -fopt-info-vec-optimized -o bench bench.c -lm
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:41:53: optimized: loop vectorized using 16 byte vectors
weno.h:41:53: optimized: loop vectorized using 64 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:41:53: optimized: loop vectorized using 64 byte vectors
weno.h:41:53: optimized: loop vectorized using 32 byte vectors
weno.h:7:27: optimized: loop vectorized using 16 byte vectors
weno.h:7:27: optimized: loop vectorized using 32 byte vectors
weno.h:7:27: optimized: loop vectorized using 16 byte vectors
weno.h:7:27: optimized: loop vectorized using 32 byte vectors
weno.h:7:27: optimized: loop vectorized using 32 byte vectors
weno.h:7:27: optimized: loop vectorized using 64 byte vectors
weno.h:7:27: optimized: loop vectorized using 64 byte vectors
```

Για την παραλληλοποίηση με AVX intrinsics, σβησαμε την συνάρτηση `weno_minus_core` και τοποθετήσαμε όλο τον κώδικα απευθείας μέσα στην `weno_minus_reference`. Αυτό το βήμα δεν είναι απαραίτητο, αλλά το βρήκαμε πιο εύκολο.

Ο βρόγχος επανάληψης γίνεται με βήματα των 8, και αρχικοποιούνται σε καταχωρητές 8 τιμές του κάθε float array και μερικοί καταχωρητές με 8 αντίγραφα του κάθε αριθμού που χρειαζόμαστε για τις πράξεις.

```

__m256 a_ = _mm256_load_ps(a+i);
__m256 b_ = _mm256_load_ps(b+i);
__m256 c_ = _mm256_load_ps(c+i);
__m256 d_ = _mm256_load_ps(d+i);
__m256 e_ = _mm256_load_ps(e+i);

__m256 coef1 = _mm256_set1_ps(4.0f/3.0f);
__m256 coef2 = _mm256_set1_ps(19.0f/3.0f);
__m256 coef3 = _mm256_set1_ps(11.0f/3.0f);
__m256 coef4 = _mm256_set1_ps(25.0f/3.0f);
__m256 coef5 = _mm256_set1_ps(31.0f/3.0f);
__m256 coef6 = _mm256_set1_ps(10.0f/3.0f);
__m256 coef7 = _mm256_set1_ps(13.0f/3.0f);
__m256 coef8 = _mm256_set1_ps(5.0f/3.0f);

```

Στην συνέχεια υπολογίζονται και αποθηκεύονται σε AVX καταχωρητές οι τιμές is0, is1, is2 με χρήση fmaddd και fmsub όπου είναι εφικτό:

```

__m256 A = _mm256_mul_ps(a_, coef1);
A = _mm256_fmsub_ps(b_, coef2, A);
A = _mm256_fmadd_ps(c_, coef3, A);
A = _mm256_add_ps(a_, A);

__m256 B = _mm256_mul_ps(b_, coef4);
B = _mm256_fmsub_ps(c_, coef5, B);

__m256 C = _mm256_mul_ps(c_, coef6);
C = _mm256_mul_ps(c_, C);

__m256 is0 = _mm256_add_ps(A, B);
is0 = _mm256_add_ps(is0, C);

```

Συνεχίζουμε την αντιστοιχη διαδικασία για το υπόλοιπο του κώδικα.

Χρησιμοποιούμε την εντολή `_mm256_rcp_ps` στα σημεία που χρειαζόμαστε κάποιο αντίστροφο.

Στο τέλος αποθηκεύουμε τα αποτελέσματα στην μνήμη.

## B)

Αποτελέσματα με αρχικό bench:


Benchmark	original	GCC	OpenMP	AVX
PEAK-LIKE	0.004017	0.000549	0.001237	0.000363
STREAM-LIKE	0.778927	0.120399	0.262018	0.101510

Όπως είναι προφανές, οι ταχύτητες όταν τα δεδομένα βρίσκονται στην κρυφή μνήμη είναι πολύ γρήγορες. Η βελτίωση είναι επίσης μεγαλύτερη όταν τα δεδομένα βρίσκονται στην κρυφή μνήμη, καθώς όταν τα δεδομένα πρέπει να φορτωθούν από την κύρια μνήμη εισάγεται μια μεγάλη καθυστέρηση που δεν μπορούμε να αποφύγουμε.

Η πιο γρήγορη μέθοδος είναι η χρήση AVX intrinsics, με αμέσως επόμενη σε ταχύτητα τα GCC optimizations. Το vectorization με OpenMP είναι σημαντικά και σταθερά πιο αργό, με 4x βελτίωση από τον αρχικό κώδικα, συγκριτικά με >10x βελτίωση από τις άλλες μεθόδους για το PEAK-LIKE benchmark, και 6-7x βελτίωση για το STREAM-LIKE.

Επεκτείνουμε το benchmark βάζοντας διαφορετικά nentries – ntimes, με στόχο προσομοίωσης διαφορετικών ποσοστών χρήσης cache.

Benchmark	original	GCC	OpenMP	AVX
0%	0.000010	0.000001	0.000004	0.000001
25%	0.000934	0.000131	0.000308	0.000089
50%	0.001887	0.000270	0.000645	0.000177
75%	0.002820	0.000388	0.000939	0.000271
PEAK-LIKE	0.003791	0.000570	0.001258	0.000419
STREAM-LIKE	0.780143	0.115920	0.265023	0.102822



Παρατηρούμε ότι η βελτίωση στην απόδοση είναι σταθερή ανεξαρτητα ποσοστού χρήσης cache, δείχνοντας την αξία αυτής της τεχνικής.

## 2. CUDA and Complex Matrix Multiplication

Εκτελέσαμε τους υπολογισμούς με 4 διαφορετικούς τρόπους:

- CUDA with Global Memory (cuda\_global.h)
- CUDA with Shared Memory (cuda\_shared.h)
- CUDA with cuBLAS Library (cuda\_cublas.h)
- CPU (cpu.h)

Η κάθε υλοποίηση περιέχει τις συναρτήσεις της στα αντιστοίχια header files.

Στην main αρχικά δεσμεύεται μνήμη για τα μητρώα (χρησιμοποιείται μονοδιάστατος πίνακας για ευχρηστία και καλύτερη τοπικότητα μνήμης), και αρχικοποιούνται κατάλληλα τα A,B,C,D.

Στην συνέχεια δεσμεύεται μνήμη και στην κάρτα γραφικών για τα A, B, C, D, και αντιγράφονται τα περιεχόμενα απο την CPU στην GPU.

Στην συνέχεια εκτελούνται με την σειρά υπολογισμοί για τις διαφορετικές μεθόδους (ενδιάμεσα τίθενται 0 οι τιμές στα μητρώα αποτελεσμάτων για αποφυγή λαθών). (computeX()).

Τέλος, συγκρίνονται τα αποτελέσματα μεταξύ των διαφόρων μεθόδων για να επιβεβαιωθούν τα σωστά αποτελέσματα.

Λογω της βιβλιοθήκης cuBLAS, η οποία περιμένει column-major indexing, αυτό χρησιμοποιήσαμε για όλες τις μεθόδους.

## A. `cuda_global.h`

Η “χαζή” μέθοδος, που χρησιμοποιεί την global μνήμη της GPU.

Στην συνάρτηση `computeCUDAGlobal`, που δέχεται ως ορίσματα τα μητρώα στην CPU στα οποία θα αποθηκευτούν τα αποτελέσματα, ορίζουμε τον αριθμό των blocks μεγέθους 8x8 (πολλαπλάσιο του warp size έτσι ώστε να μην έχουμε ανενεργά threads) έτσι ώστε να υπολογίζονται όλα τα δεδομένα. Η καλύτερη απόδοση συμβαίνει για blocks 8x8,

Στην συνέχεια καλούνται με την σειρά οι απαραίτητες συναρτήσεις `matMult` / `vecAdd` / `VecSub` για τον υπολογισμό της ζητούμενης πράξης. Στο τέλος, αποθηκεύονται τα τελικά αποτελέσματα στις μεταβλητές του επεξεργαστή.

## B. `cuda_shared.h`

Μια πιο “έξυπνη” λύση, καθώς χρησιμοποιεί shared μνήμη, μειώνοντας την καθυστέρηση και χρησιμοποιώντας πιο ορθά την μνήμη της GPU.

Η λειτουργία είναι παρόμοια με την `global`, με την διαφορά ότι χρησιμοποιείται `shared` μνήμη.


Για κάποιο λόγο, για μεγάλες τιμές του  $N$ , η `shared` και η `global` υλοποιήσεις αποτυγχάνουν κάποιες φορές, επιστρέφοντας χωρίς αποτελέσματα. Υποψιαζόμαστε ότι σε περίπτωση που η VRAM δεν αρκεί, απλά επιστρέφει χωρίς αποτέλεσμα. Η παρακάτω υλοποίηση είναι και γρηγορότερη και λειτουργεί ανεξάρτητα μεγέθους.



## C. `cuda_cublas.h`

Η καλύτερη λύση, καθώς χρησιμοποιεί την `optimized` βιβλιοθήκη cuBLAS για τους υπολογισμούς. Η διαφορά γίνεται πιο εμφανής με μεγαλύτερα  $N$ . Μέσω της μεθόδου `cublasDgemm` γίνονται οι απαραίτητες πράξεις και τα δεδομένα αντιγράφονται στην CPU.

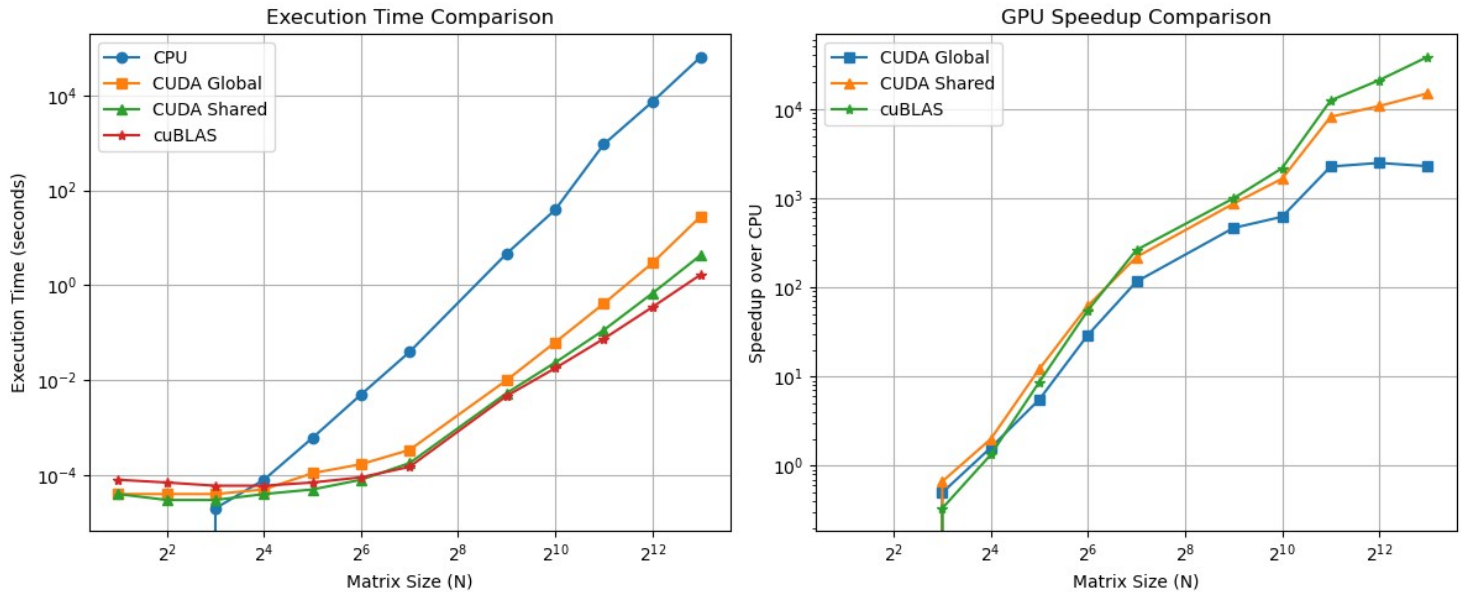
Επιχειρήσαμε να αξιοποιήσουμε `streams` για τον παράλληλο υπολογισμό των  $E$  και  $F$ , αλλά η απόδοση παρέμεινε η ίδια. Κοιτάζοντας την χρήση της GPU μέσω NVTOP κατά την διάρκεια λειτουργίας, είναι αρκετά κοντά στο 100%. Αυτό δείχνει ότι και με χρήση πολλαπλών `streams` δεν θα υπήρχε παραπάνω βελτίωση, αφού η GPU λειτουργεί ήδη κοντά στο έπακρο των δυνατοτήτων της.



## D. `cpu.h`

Σε αυτό το αρχείο, πέραν των συναρτήσεων για τους υπολογισμούς (που είναι αρκετά παρόμοιες με την CUDA υλοποίησης, απλώς για CPU), έχουμε τοποθετήσει και τις συναρτήσεις για `initialization` και `cleanup`.

## Ε. Αποτελέσματα



Παρατηρούμε γραμμική επιτάχυνση για όλες τις υλοποιήσεις συγκριτικά με τον CPU υπολογισμό, αλλά για  $N = 2^{11}$  και μετά παρατηρείται η επιτάχυνση να επιβραδύνει και για τις 3 υλοποιήσεις. Η CUDA Global μάλιστα μοιάζει να σταματά να επιταχύνει περαιτέρω. Θα θέλαμε να τρέξουμε την σύγκριση αυτή και για μεγαλύτερα μεγέθη, αλλά η επεξεργασία CPU είναι πολύ χρονοβόρα.

Ως τελικό συμπέρασμα αυτής της εργασίας έχουμε ότι η παραλληλοποίηση με GPUs είναι ένα εξαιρετικά δυνατό εργαλείο, και η χρήση εξειδικευμένων βιβλιοθηκών όπου αυτές υπάρχουν είναι επιθυμητή.